

Formulario Probabilidad y Procesos Estocásticos Tercer Parcial

Roberto Navarro Castañeda

Diciembre 2023

1. Secuencias de Variables aleatorias

- Dadas n V.A $\mathbf{X}_1, \dots, \mathbf{X}_n$ se define la distribución conjunta:

$$F(x_1, \dots, x_n) = P(\mathbf{X}_1 \leq x_1, \dots, \mathbf{X}_n \leq x_n) \quad (1)$$

$$P((\mathbf{x}_1, \dots, \mathbf{x}_n) \in D) = \int_D \dots \int f(x_1, \dots, x_n) dx_1 \dots dx_n \quad (2)$$

- Y la densidad conjunta:

$$f(x_1, \dots, x_n) = \frac{\partial F(x_1, \dots, x_n)}{\partial x_1 \dots \partial x_n} \quad (3)$$

- La integral respecto a todo el espacio es igual a 1:

$$F(\infty, \dots, \infty) =$$

$$\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, \dots, x_n) dx_1 \dots dx_n \quad (4)$$

$$F(\infty, \dots, \infty) = 1 \quad (5)$$

- **Funciones de distribución marginales y densidades marginales:**

- Sea una función de distribución conjunta $F(x_1, x_2, x_3, x_4)$ la marginal $F(x_1, x_3)$ se define

$$F(x_1, x_3) = F(x_1, \infty, x_3, \infty) \quad (6)$$

- Y la densidad marginal:

$$f(x_1, x_3) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x_1, x_2, x_3, x_4) dx_2 dx_4 \quad (7)$$

- **Densidad condicional:**

- Se denota la densidad condicional de $\mathbf{x}_1, \dots, \mathbf{x}_k$ asumiendo que se cumplen $\mathbf{x}_{k+1}, \dots, \mathbf{x}_n$

$$f(x_1, \dots, x_n | x_{k+1}, \dots, x_n) = \frac{f(x_1, \dots, x_k, x_{k+1}, \dots, x_n)}{f(x_{k+1}, \dots, x_n)} \quad (8)$$

- Por ejemplo:

$$f(x_1 | x_2, x_3) = \frac{f(x_1, x_2, x_3)}{f(x_2, x_3)} \quad (9)$$

$$F(x_1 | x_2, x_3) = \frac{\int_{-\infty}^{x_1} f(\xi_1, x_2, x_3) d\xi_1}{f(x_2, x_3)} \quad (10)$$

Probabilidad Total:

$$f(x_1, \dots, x_n) = f(x_n | x_{n-1}, \dots, x_1) \dots f(x_2 | x_1) f(x_1) \quad (11)$$

Variables aleatorias independientes

- Se dice que si n variables aleatorias x_1, \dots, x_n son **independientes** entonces la distribución y densidad conjunta:

$$F(x_1, \dots, x_n) = F(x_1) \cdots F(x_n) \quad (12)$$

$$f(x_1, \dots, x_n) = f(x_1) \cdots f(x_n) \quad (13)$$

- Si las variables aleatorias x_1, \dots, x_n son **independientes** entonces **las funciones de ellas** también serán **independientes**:

$$g_1(\mathbf{x}_1), \dots, g_n(\mathbf{x}_n) \quad (14)$$

Independencia de grupos

- Existen grupos de variables aleatorias que son independientes. Se dice que las V.A. $\mathbf{x}_1, \dots, \mathbf{x}_k$ son independientes de $\mathbf{x}_{k+1}, \dots, \mathbf{x}_n$ si:

$$f(x_1, \dots, x_k, x_{k+1}, \dots, x_n) =$$

$$f(x_1, \dots, x_k) f(x_{k+1}, \dots, x_n) \quad (15)$$

- Una función del primer grupo es independiente de otra del segundo grupo:

$$g(\mathbf{x}_1, \dots, \mathbf{x}_k) \text{ es independiente de}$$

$$h(\mathbf{x}_{k+1}, \dots, \mathbf{x}_n) \quad (16)$$

Esperanza

- La de una función $g(\mathbf{x}_1, \dots, \mathbf{x}_n)$ de n V.A. está dada por:

$$\begin{aligned} E(g(\mathbf{x}_1, \dots, \mathbf{x}_n)) &= \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(x_1, \dots, x_n) f(x_1, \dots, x_n) dx_1 \cdots dx_n \end{aligned} \quad (17)$$

- La esperanza de la suma de V.A. es una suma de esperanzas: $E(g_1 + \cdots + g_k) = E(g_1) + \cdots + E(g_k)$.

- La esperanza condicional se obtiene insertando (17) en la densidad condicional:

$$E(\mathbf{x}_1 | x_2, \dots, x_n) = \int_{-\infty}^{\infty} x_1 f(x_1 | x_2, \dots, x_n) dx_1 \quad (18)$$

$$E(\mathbf{x}_1 | x_2, \dots, x_n) = \frac{\int_{-\infty}^{\infty} x_1 f(x_1, x_2, \dots, x_n) dx_1}{f(x_2, \dots, x_n)} \quad (19)$$

- **Teorema:**

$$E(E(\mathbf{x}_1 | x_2, \dots, x_n)) = E(\mathbf{x}_1) \quad (20)$$

- Si \mathbf{x}_1 es independiente de $\mathbf{x}_2, \dots, \mathbf{x}_n$

$$E(\mathbf{x}_1 | x_2, \dots, x_n) = E(\mathbf{x}_1) \quad (21)$$

V.A. descorrelacionadas

- Se definen las V.A. $\mathbf{X}_1, \dots, \mathbf{X}_n$ descorrelacionadas si

$$E(\mathbf{X}_i \mathbf{X}_j) = E(\mathbf{X}_i) E(\mathbf{X}_j) \quad \forall i \neq j \quad (22)$$

$$C_{\mathbf{X}_i \mathbf{X}_j} = 0 \quad \forall i \neq j \quad (23)$$

- **Teorema:** Si $\mathbf{X}_1, \dots, \mathbf{X}_n$ son independientes entonces son descorrelacionadas:

$$E(\mathbf{X}_1, \dots, \mathbf{X}_n) = E(\mathbf{X}_1) \cdots E(\mathbf{X}_n) \quad (24)$$

- Además:

$$E(g_1(\mathbf{X}_1) \cdots g_n(\mathbf{X}_n)) = E(g_1(\mathbf{X}_1)) E(g_2(\mathbf{X}_2)) \cdots E(g_n(\mathbf{X}_n)) \quad (25)$$

- Si $(\mathbf{X}_1, \dots, \mathbf{X}_k)$ es independiente de $(\mathbf{X}_{k+1}, \dots, \mathbf{X}_n)$, entonces:

$$\begin{aligned} E(g((\mathbf{X}_1, \dots, \mathbf{X}_k)) h(\mathbf{X}_{k+1}, \dots, \mathbf{X}_n)) &= \\ E(g((\mathbf{X}_1, \dots, \mathbf{X}_k)) E(h(\mathbf{X}_{k+1}, \dots, \mathbf{X}_n))) &= \end{aligned} \quad (26)$$

V.A ortogonales y descorrelacionadas Media y Varianza en Estadística

- Las V.A $\mathbf{X}_1, \dots, \mathbf{X}_n$ son **ortogonales** si:

$$E(\mathbf{X}_i \mathbf{X}_j) = 0 \quad \forall i, j \quad i \neq j \quad (27)$$

- Si las V.A \mathbf{X}_i son descorrelacionadas

$$\sigma_{\mathbf{X}_1 + \mathbf{X}_2 + \dots + \mathbf{X}_n}^2 = \sigma_{\mathbf{X}_1}^2 + \sigma_{\mathbf{X}_2}^2 + \dots + \sigma_{\mathbf{X}_n}^2 \quad (28)$$

- Si las V.A \mathbf{X}_i son ortogonales:

$$E((\mathbf{X}_1 + \dots + \mathbf{X}_n)^2) = E((\mathbf{X}_1)^2) + \dots + E((\mathbf{X}_n)^2) \quad (29)$$

- Sean las V.A \mathbf{X}_i , $i = 1, \dots, n$

- La **Media estadística** \bar{X} es:

$$\bar{X} = \frac{\mathbf{X}_1 + \dots + \mathbf{X}_n}{n} \quad (36)$$

- Y la **Varianza estadística** es:

$$\bar{V} = \frac{(\mathbf{X}_1 - \bar{X})^2 + \dots + (\mathbf{X}_n - \bar{X})^2}{n} \quad (37)$$

- **Teorema:** Suponga que las V.A \mathbf{X}_i son **descorrelacionadas** y que cada una de ellas tienen la misma **media y varianza**:

$$E(\mathbf{X}_i \mathbf{X}_j) = E(\mathbf{X}_i) E(\mathbf{X}_j) \quad (38)$$

$$E(\mathbf{X}_i) = \eta; \quad \sigma_{\mathbf{X}_i}^2 = \sigma^2 \quad (39)$$

- Entonces:

$$E(\bar{X}) = \eta \quad \sigma_{\bar{X}}^2 = \frac{\sigma^2}{n} \quad (40)$$

$$E(\bar{V}) = \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n} \sigma^2 \quad (41)$$

Momentos y Función característica

- Sean las V.A $\mathbf{X}_1, \dots, \mathbf{X}_n$ sus *momentos* de orden $r = k_1 + \dots + k_n$ son:

$$m_{k_1, \dots, k_n} = E(\mathbf{X}_1^{k_1}, \dots, \mathbf{X}_n^{k_n}) \quad (30)$$

- Sean las V.A $\mathbf{X}_1, \dots, \mathbf{X}_n$ su *función característica* es:

$$\Phi(\omega_1, \omega_2, \dots, \omega_n) = E(e^{j(\omega_1 \mathbf{X}_1 + \omega_2 \mathbf{X}_2 + \dots + \omega_n \mathbf{X}_n)}) \quad (31)$$

- Si son independientes:

$$E\{e^{j\omega_1 \mathbf{X}_1} \dots e^{j\omega_n \mathbf{X}_n}\} = E\{e^{j\omega_1 \mathbf{X}_1}\} \cdot E\{e^{j\omega_2 \mathbf{X}_2}\} \dots E\{e^{j\omega_n \mathbf{X}_n}\} \quad (32)$$

- Y se llega a que:

$$\Phi(\omega_1, \omega_2, \dots, \omega_n) = \Phi(\omega_1) \dots \Phi(\omega_n) \quad (33)$$

- Los momentos conjuntos:

$$\frac{\partial^r \Phi(0, \dots, 0)}{\partial \omega_1^{k_1} \dots \partial \omega_n^{k_n}} = j^r m_{k_1, \dots, k_n} \quad (34)$$

- **Ejemplo:** La función característica de una suma de variables aleatorias independientes es igual al producto de las funciones características marginales de cada V.A

- **Convolución:** Sea $\mathbf{Z} = \mathbf{X}_1 + \dots + \mathbf{X}_n$

$$f_{\mathbf{Z}}(z) = f_1(z) * \dots * f_n(z) \quad (35)$$

Conceptos de Convergencia de V.A

- **Def.1:** La secuencia de V.A $\{\mathbf{X}_n\}$ converge **por todos lados** (*every where*) si:

$$\lim_{n \rightarrow \infty} \mathbf{X}_n = \mathbf{X} \quad (42)$$

- Esta definición pide que absolutamente todas las secuencias de $\{\mathbf{X}_n(\xi)\}$ converjan.

- **Def.2:** La secuencia de V.A $\{\mathbf{X}_n\}$ converge con **Probabilidad 1** (*almost everywhere, almost sure*) si:

$$\lim_{n \rightarrow \infty} P\{\mathbf{X}_n \rightarrow \mathbf{X}\} = 1 \quad (43)$$

- La definición anterior indica que para el conjunto de resultados ξ donde:

$$\lim_{n \rightarrow \infty} \mathbf{x}_n(\xi) = \mathbf{x}(\xi) \quad (44)$$

- Tiene probabilidad 1 y que aquellos para los cuales converge tiene probabilidad 0.

- **Def.3:** La secuencia de V.A $\{ \mathbf{X}_n \}$ converge en **media cuadrática** (m.s) si:

$$\lim_{n \rightarrow \infty} E\{|x_n - x|^2\} = 0 \quad (45)$$

- **Def.4:** La secuencia de V.A $\{ \mathbf{X}_n \}$ converge en **Probabilidad (P)**:

$$\lim_{n \rightarrow \infty} P\{|x_n - x| > \epsilon\} = 0 \quad \forall \epsilon \quad (46)$$

- **Def. 5:** La secuencia de la V.A $\{ \mathbf{X}_n \}$ converge en **distribución (d)** si dadas: $F_n(x)$ la distribución de X_n y $F(x)$ la distribución de \mathbf{X} , entonces:

$$\lim_{n \rightarrow \infty} F_n(x) = F(x) \quad (47)$$

- para todo x en el cual $F_n(x)$ es continua.
- **Teorema:** si la consecuencia de V.A $\{ \mathbf{X}_n \}$ converge en **converge en media cuadrática** entonces **converge en probabilidad**.
- **Criterio de Cauchy:** Si el límite \mathbf{X} no es conocido, podemos hablar aún de convergencia si:

$$E\{|\mathbf{X}_{n+m} - \mathbf{X}_n|^2\} < \epsilon \quad n > n_0 \quad y \quad m > 0 \quad (48)$$

Ley de los grandes números

- **Bernoulli:** según Bernoulli: Si la probabilidad de un evento A en un experimento dado es p y el experimento es repetido n veces entonces:

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{k}{n} - p\right| \leq \epsilon\right\} = 1 \quad \forall \epsilon > 0 \quad (49)$$

- Donde k es el número de veces que A ocurre
- **Tchebycheff:** Según Tchebycheff si las V.A X_n son descorrelacionadas con:

$$E\{X_i\} = \eta_i; \quad \sigma_{X_i}^2 = \sigma_i^2 \quad (50)$$

- Y además satisface que:

$$\sigma_{\bar{X}_n}^2 = \frac{\sigma_i^2 + \dots + \sigma_n^2}{n} \rightarrow 0 \quad (51)$$

- Entonces si:

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} \quad (52)$$

- Se tiene que:

$$\lim_{n \rightarrow \infty} E\left\{\left(\bar{X} - \frac{1}{n} \sum_{i=1}^n \eta_i\right)^2\right\} = 0 \quad (53)$$

- \bar{X} es un buen estimado del promedio de las esperanzas matemáticas de las X_i cuando el número de experimentos es bastante grande.

- Entonces:

$$E\{(\bar{X} - \eta)^2\} = 0 \quad (54)$$

- Entonces:

$$\lim_{n \rightarrow \infty} P\{|\bar{X} - \eta| > \epsilon\} \rightarrow 0 \quad \forall \epsilon \quad (55)$$

- **Markoff:**

$$\sigma_{\bar{\mathbf{x}}_n} \rightarrow 0 \quad \text{para } n \rightarrow \infty \quad (56)$$

$$\sigma_{\bar{\mathbf{x}}_n} = E\left\{\left[\bar{\mathbf{x}}_n - \frac{\eta_1 + \dots + \eta_n}{n}\right]^2\right\} \rightarrow 0 \quad (57)$$

Teorema del límite central

- La densidad $f_x(x)$ de una suma de V.A independientes X_i (con igual o diferente distribución), bajo ciertas condiciones se aproxima a una densidad normal cuando $n \rightarrow \infty$.

$$f(x) \simeq \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\eta)^2}{2\sigma^2}} \quad (58)$$

2. Procesos Estocásticos

- Sea un proceso estocástico $X(t)$ se define:

- **Función de distribución de primer orden:**

$$F(x; t) = P \{ \mathbf{X}(t) \leq x \} \quad (59)$$

- **Función de densidad de primer orden**

$$f(x; t) = \frac{\partial F(x; t)}{\partial x} \quad (60)$$

- También:

$$F(x; t) = \int_{-\infty}^x f(x; t) dx \quad (61)$$

- **La función de distribución conjunta de segundo orden** se define:

$$F(x_1, x_2; t_1, t_2) = P \{ \mathbf{X}(t_1) \leq x_1, \mathbf{X}(t_2) \leq x_2 \} \quad (62)$$

- **La densidad conjunta de segundo orden** se define:

$$f(x_1, x_2; t_1, t_2) = \frac{\partial^2 F(x_1, x_2; t_1, t_2)}{\partial x_1 \partial x_2} \quad (63)$$

- También:

$$F(x_1, x_2; t_1, t_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f(x_1, x_2; t_1, t_2) dx_1 dx_2 \quad (64)$$

- Y la función de distribución marginal y la densidad marginal:

$$F(x_1, \infty; t_1, t_2) = P \{ \mathbf{X}(t_1) \leq x_1, \mathbf{X}(t_2) \leq \infty \} =$$

$$P \{ \mathbf{X}(t_1) \leq x_1 \} = F(x_1; t_1) \quad (65)$$

$$f(x_1; t_1) = \int_{-\infty}^{\infty} f(x_1, x_2; t_1, t_2) dx_2 \quad (66)$$

- La función de **Distribución de n-ésimo orden** se define:

$$F(x_1, \dots, x_n; t_1, \dots, t_n) =$$

$$P \{ \mathbf{X}(t_1) \leq x_1, \dots, \mathbf{X}(t_n) \leq x_n \} \quad (67)$$

$$F(x_1, \dots, x_n; t_1, \dots, t_n) =$$

$$\int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(x_1, \dots, x_n; t_1, \dots, t_n) dx_1, \dots, dx_n \quad (68)$$

- **La densidad condicional**

$$f(x_1; t_1 | X_2(t_2) = x_2) = \frac{f(x_1, x_2; t_1, t_2)}{f(x_2; t_2)} \quad (69)$$

- **La media** $\eta(t)$ de un proceso estocástico $\mathbf{X}(t)$ se define (t fijo)

$$\eta(t) = E \{ \mathbf{X}(t) \} = \int_{-\infty}^{\infty} x(t) f(x; t) dx \quad (70)$$

- La **Autocorrelación** (*O solo Correlación*) $R_x(t_1, t_2)$ de un proceso estocástico $\mathbf{X}(t)$ real escalar (t_1 y t_2 fijos) se definen como:

$$R_x(t_1, t_2) = E \{ \mathbf{X}(t_1) \mathbf{X}(t_2) \} \quad (71)$$

$$R_x(t_1, t_2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_1 x_2 f(x_1, x_2; t_1, t_2) dx_1 dx_2 \quad (72)$$

- La **autocovarianza** $C(t_1, t_2)$ de la V.A $\mathbf{X}(t_1)$ y $\mathbf{X}(t_2)$:

$$C(t_1, t_2) = E \{ [\mathbf{x}(t_1) - \eta(t_1)] [\mathbf{x}(t_2) - \eta(t_2)] \} \quad (73)$$

$$C(t_1, t_2) = R(t_1, t_2) - \eta(t_1) \eta(t_2) \quad (74)$$

- La varianza de la V.A $\mathbf{X}(t)$ está dada por:

$$\sigma_{\mathbf{X}(t)}^2 = C(t, t) = R(t, t) - \eta^2(t) \quad (75)$$

Proceso de Poisson

- La probabilidad de tener k punto en un intervalo de longitud t es igual a:

$$\frac{e^{-\lambda t} (\lambda t)^k}{k!} \quad (76)$$

- Y los puntos que no se traslapan/superponen en un intervalo, se dicen *independientes*.
- La variable aleatoria $\mathbf{x}(t)$ se define asumiendo: $\mathbf{x}(0) = 0$ y que el *número de puntos en el intervalo* (t_1, t_2) es igual a $\mathbf{x}(t_1) - \mathbf{x}(t_2)$

Caminata Aleatoria

- Como ejemplo se supone que se lanza una moneda *bien equilibrada* cada T segundos y que se efectúa un *número infinito* de lanzamientos. Si al lanzar la moneda se obtiene sol, se dará un paso a la derecha de longitud s , sino se dará un paso en dirección opuesta. La posición al instante t será $\mathbf{x}(t)$. A cada instante se obtiene una V.A \mathbf{x}_i , donde $i \in 1, 2, \dots, n$ que toma los valores $\pm s$ tal que:

$$P(\mathbf{x}_i = s) = p = \frac{1}{2} \quad P(\mathbf{x}_i = -s) = q = \frac{1}{2} \quad (77)$$

$$E\{\mathbf{x}_i = 0\} \quad E\{\mathbf{x}_i^2\} = s^2 \quad (78)$$

- La posición al instante nT estará representada por:

$$\mathbf{X}(nT) = \mathbf{X}_1 + \dots + \mathbf{X}_n \quad (79)$$

- La media del proceso estocástico $\mathbf{x}(nT)$ está dada por:

$$E\{\mathbf{X}(nT)\} = E\{\mathbf{X}_1\} + \dots + E\{\mathbf{X}_n\} = 0 \quad (80)$$

- Como las V.A son independientes y tienen media cero:

$$\sigma_x^2(nT) = E\{\mathbf{x}^2(nT)\} = E\{\mathbf{x}_i^2\} + \dots + E\{\mathbf{x}_n^2\} = ns^2 \quad (81)$$

- Ahora suponiendo que en los lanzamientos se obtuvieron k soles. Si esto sucede, la posición al tiempo nT es:

$$\mathbf{X}(nT) = ks - (n - k)s = (2k - n)s \quad (82)$$

- Definiendo $r = 2k - n$ con lo que $k = \frac{r+n}{2}$

$$\mathbf{X}(nT) = rs \quad (83)$$

- Ahora:

$$P(\mathbf{x}(nT) = rs) = P(k - \text{soles}) =$$

$$\binom{n}{k} \left(\frac{1}{2}\right)^k \left(\frac{1}{2}\right)^{n-k} = \binom{n}{k} \left(\frac{1}{2}\right)^n \quad (84)$$

- Por el teorema de Moivre-Laplace, cuando $n \rightarrow \infty$, la distribución *binomial* se aproxima por una *normal*, en:

$$P(k - \text{soles}) = \binom{n}{k} \left(\frac{1}{2}\right)^n \rightarrow \frac{1}{\sqrt{2\pi npq}} e^{-\frac{(k-np)^2}{2npq}} \quad (85)$$

- Sustituimos k, p y q :

$$(k - np)^2 = -\left[\frac{r+n}{2} - \frac{n}{2}\right]^2 = \left[\frac{r}{2}\right]^2 \quad (86)$$

- Se tiene:

$$\lim_{n \rightarrow \infty} p(\mathbf{X}(nT) = rs) = \frac{1}{\sqrt{\frac{2\pi n}{4}}} e^{-\frac{\left(\frac{r}{2}\right)^2}{\frac{2n}{4}}} \quad (87)$$

- La densidad $\mathbf{X}(nT)$ en el *límite* es una *densidad normal*.

- Definiendo una nueva variable Y_1 :

$$\mathbf{Y}_1 = \mathbf{X}(n_1T) - \mathbf{X}(n_2T) \quad (88)$$

- Significando el incremento (o decremento) que hay en la posición en el intervalo de tiempo $n_2T - n_1T$.

- Notar que:

$$p(\mathbf{Y}_1 = r's) = p(\mathbf{X}(n_1T) - \mathbf{X}(n_2T) = r's); \quad n_1 > n_2 \quad (89)$$

- Coincide con la probabilidad de obtener un cierto número de caras en $n_2T - n_1T$

- Si se tiene ahora:

$$p(\mathbf{Y}_2 = r''s) = (\mathbf{X}(n_3T) - \mathbf{X}(n_4T) = r''s); \quad (90)$$

$$n_2 > n_3 > n_4 \quad (91)$$

- coincide con la probabilidad de obtener otro cierto número de caras en $n_3T - n_4T$. Por otro lado el número de caras que aparecen en $n_2T - n_1T$ es independiente del que aparece en $n_3T - n_4T$, por ser disjuntos los intervalos de tiempo considerados, con lo que \mathbf{Y}_1 y \mathbf{Y}_2 son independientes, o lo que es lo mismo, los incrementos de posición en dos intervalos disjuntos de tiempo son independientes. Por esta razón, se dice que **la caminata aleatoria es un proceso estocástico con incrementos independientes**. Finalmente calculemos:

$$E\{\mathbf{X}(n_iT) - \mathbf{X}(n_jT)\} =$$

$$E\{\mathbf{X}(n_iT)\} - E\{\mathbf{X}(n_jT)\} \quad (92)$$

$$n_iT \neq n_jT \quad (93)$$

- Sean $n_1 > n_2 > n_3 > n_4$

$$E\{[\mathbf{X}(n_1T) - \mathbf{X}(n_2T)][\mathbf{X}(n_3T) - \mathbf{X}(n_4T)]\} \quad (94)$$

- Recordemos que los incrementos de posición son independientes y entonces descorrelacionados y además la media de ellos es cero, entonces son ortogonales, con lo que:

$$E\{[\mathbf{X}(n_1T) - \mathbf{X}(n_2T)][\mathbf{X}(n_3T) - \mathbf{X}(n_4T)]\} = 0 \quad (95)$$

Proceso de Wiener-Lévy

- Se toma del proceso de la caminata aleatoria cuando:

$$t = nT \quad (96)$$

- La media y varianza de $\mathbf{W}(t)$ está dada por:

$$E\{\mathbf{X}(t)\} = 0 \quad (97)$$

$$E\{\mathbf{X}^2(nT)\} = E\{\mathbf{X}^2(t)\} = \frac{ts^2}{T} \quad (98)$$

- Suponiendo que se mantiene a t constante, pero se hace que s y T tiendan a cero ($T \rightarrow 0$). La varianza de $\mathbf{x}(t)$ se mantendrá finita si $s^2 = \alpha T$ tal que:

$$\lim_{T \rightarrow 0} E\{\mathbf{X}^2(t)\} = \alpha t \quad (99)$$

- De esto, se define al **Proceso de Wiener** $\mathbf{w}(t)$ como el límite de la posición en la caminata aleatoria:

$$\mathbf{W}(t) = \lim_{T \rightarrow 0} \mathbf{W}(t) \quad (100)$$

- La *autocorrelación* de $\mathbf{W}(t)$ es:

$$R(t_1, t_2) = \begin{cases} \alpha t_2, & t_1 \geq t_2 \\ \alpha t_1, & t_1 \leq t_2 \end{cases} \quad (101)$$

- **Propiedades del proceso de Wiener-Lévy**

$$\mathbf{w}(t = 0) = 0 \quad (102)$$

$$E\{\mathbf{W}(t)\} = 0 \quad (103)$$

$$E\{\mathbf{W}^2(t)\} = \alpha t \quad (104)$$

- Si $t_1 > t_2 > t_3 > t_4$

$$E\{[\mathbf{w}(t_1) - \mathbf{w}(t_2)][\mathbf{w}(t_3) - \mathbf{w}(t_4)]\} = 0 \quad (105)$$

- La V.A $\mathbf{w}(t)$ es *normal distribuida*. Si w y t se eligen tal que:

$$w = rs \quad t = nT \quad (106)$$

- Entonces:

$$\frac{r}{\sqrt{n}} = \frac{\frac{w}{s}}{\sqrt{\frac{t}{T}}} = \frac{w}{\sqrt{\alpha t}} \quad (107)$$

- De esto:

$$P\{\mathbf{x}(t) \leq w\} \simeq \frac{1}{2} + \operatorname{erf} \frac{w}{\sqrt{\alpha t}} \quad (108)$$

- Haciendo $T \rightarrow 0$, se tiene que $n \rightarrow \infty$ y $r = w\sqrt{\frac{n}{\alpha t}}$ tiendan al infinito como \sqrt{n} y la densidad $f(w; t)$ está dada por:

$$f(w; t) = \frac{1}{\sqrt{2\pi\alpha t}} e^{-\frac{w^2}{2\alpha t}} \quad (109)$$

Mas conceptos y definiciones

- Un *proceso estocástico* está **completamente determinado** si se conocen sus funciones de distribución de orden n para todo n y para todo t_1, \dots, t_n
- Un **proceso bidimensional** consiste de dos *procesos estocásticos*:

$$\mathbf{X}(t) \quad \mathbf{Y}(t)$$

- Y este queda **completamente determinado** si se conoce la función de **distribución conjunta** de las variables aleatorias:

$$\mathbf{X}(t_1), \dots, \mathbf{X}(t_n), \mathbf{Y}(t'_1), \dots, \mathbf{Y}(t'_m)$$

- Para alguna $t_1, \dots, t_n, t'_1, \dots, t'_m$
- La **correlación cruzada** $\mathbf{R}_{\mathbf{xy}}$ de los *procesos estocásticos* $\mathbf{X}(t)$ y $\mathbf{Y}(t)$ se define como:

$$R_{xy}(t_1, t_2) = E\{\mathbf{X}(t_1)\mathbf{Y}(t_2)\} \quad (110)$$

- La **Covarianza cruzada** C_{xy} de los *procesos estocásticos* $\mathbf{X}(t)$ y $\mathbf{Y}(t)$ se define como:

$$C_{xy}(t_1, t_2) = E\{[\mathbf{X}(t_1) - \eta_x(t_1)][\mathbf{Y}(t_2) - \eta_y(t_2)]\} \quad (111)$$

- Donde $\eta_x(t_1) = E\{\mathbf{X}(t_1)\}$ y $\eta_y(t_2) = E\{\mathbf{Y}(t_2)\}$
- El *proceso estocástico* es un *proceso estocástico* con **incrementos descorrelacionados (independientes) (ortogonales)** si para intervalos disjuntos de tiempo:

$$\mathbf{Y}_i = \{\mathbf{X}(t_i) - \mathbf{X}(t_{i+1})\} \quad (112)$$

- **Ejemplo:** un proceso estocástico con incrementos independientes es la Caminata Aleatoria, también esta es un proceso estocástico con incrementos ortogonales. Otros ejemplos de este tipo son el proceso estocástico de **Wiener** y el de **Poisson**.

- Es una sucesión de V.A descorrelacionadas (independientes) (ortogonales).

- **Def:** Dos procesos estocásticos $\mathbf{X}(t)$ y $\mathbf{Y}(t)$ son **independientes** ssi: $\mathbf{X}(t_1), \dots, \mathbf{X}(t_n)$ son **independientes** de $\mathbf{Y}(t'_1), \dots, \mathbf{Y}(t'_n)$ $\forall n$ y $\forall t_1, \dots, t_n, t'_1, \dots, t'_n$

- **Def:** Dos procesos estocásticos $\mathbf{X}(t)$ y $\mathbf{Y}(t)$ son **descorrelacionados** si para alguna t_1 y t_2 se tiene:

$$R_{\mathbf{xy}}(t_1, t_2) = \eta_{\mathbf{x}}(t_1)\eta_{\mathbf{y}}(t_2) \quad (113)$$

- O, lo que es equivalente:

$$C_{\mathbf{xy}}(t_1, t_2) = 0 \quad (114)$$

- Se dicen **ortogonales** si:

$$R_{\mathbf{xy}}(t_1, t_2) = 0 \quad (115)$$

Procesos Normales

- Un proceso $\mathbf{X}(t)$ se dice *normal* si las V.A:

$$\mathbf{X}(t_1), \dots, \mathbf{X}(t_n) \quad (116)$$

- Son conjuntamente normales para alguna t_1, \dots, t_n .

- Un proceso estocástico normal *queda definido* si se conoce su media $\eta(t)$ y su correlación $R(t_1, t_2)$.

- La *densidad* de primer orden está dada por:

$$f(x, t) = \frac{1}{\sqrt{2\pi C(t, t)}} e^{-\frac{(x - \eta(t))^2}{2C(t, t)}} \quad (117)$$

- Con $\eta(t) = E\{\mathbf{X}(t)\}$ y $C(t, t) = \sigma_x^2$

Procesos estacionarios

- **Def:** Se dice que un proceso estacionario es **Estacionario en sentido estricto** si sus características estadísticas *no se ven afectas por traslaciones en tiempo*.

$$\mathbf{x}(t) \text{ y } \mathbf{x}(t + \epsilon)$$

- Un proceso $\mathbf{x}(t)$ es estacionario en sentido estricto ssi:

$$f(x_1, \dots, x_n; t_1, \dots, t_n) = f(x_1, \dots, x_n; t_1 + \tau, \dots, t_n + \tau) \quad \forall \tau \quad (118)$$

- En particular:

$$f(x; t) = f(x; t + \tau) \quad \forall t, \forall \tau \quad (119)$$

- Esto implica que $f(x; t)$ no es función del tiempo.
- Además si $t_1 = t$ y $t_2 = t + \tau$:

$$\begin{aligned} f(x_1, x_2; t_1, t_2) &= f(x_1, x_2; t, t + \tau) \\ &= f(x_1, x_2; t + \tau, t + 2\tau) \end{aligned} \quad (120)$$

- La función de densidad conjunta de segundo orden es función solamente de τ :

$$f(x_1, x_2; t_1, t_2) = f(x_1, x_2; \tau) \quad (121)$$

- Puesto que la función de densidad de primer orden es constante:

$$E \{ \mathbf{X}(t) \} = \eta = \text{constante} \quad (122)$$

- Como la densidad des segundo orden es función de τ :

$$R(t_1, t_2) = R(\tau) \quad (123)$$

- **Def:** Se dice que un proceso $\mathbf{x}(t)$ es **estacionario de orden k** si (88) se cumple, no para alguna n , solo para $n \leq k$.

- **Def:** Se dice que un proceso estocástico es **débilmente estacionario (estacionario en sentido amplio)** si:

$$E \{ \mathbf{X}(t) \} = \eta \text{ constante} \quad (124)$$

$$R(t_1, t_2) = R(\tau) \text{ con } t_2 - t_1 = \tau \quad (125)$$

- **Def:** Dos procesos $\mathbf{x}(t)$ y $\mathbf{y}(t)$ se dicen **des-correlacionados** si para alguna t_1, t_2 :

$$R_{\mathbf{x}, \mathbf{y}}(t_1, t_2) = \eta_x(t_1) \eta_y(t_2) \quad (126)$$

- Esto es:

$$C_{xy}(t_1, t_2) = 0 \quad (127)$$

- Y se dicen ortogonales:

$$R_{xy}(t_1, t_2) = 0 \quad (128)$$

Sistemas invariantes sin memoria

- Sea g un operador determinista y la señal $\mathbf{x}(t)$ un proceso estocástico estacionario. Se asume una salida $\mathbf{y}(t)$ de un sistema relacionada con la entrada:

$$\mathbf{x}(t) = g[\mathbf{x}(t)] \quad (129)$$

- Donde $g(x)$ no es una función de t . Ahora, si la salida del sistema para $\mathbf{x}(t + \epsilon)$ es:

$$\mathbf{y}(t + \epsilon) = g[\mathbf{x}(t + \epsilon)] \quad (130)$$

- Se dice que el sistema es **invariante en el tiempo**.
- La esperanza de $\mathbf{y}(t)$ se define:

$$E \{ \mathbf{y}(t) \} = \int_{-\infty}^{\infty} g(x) f_x(x; t) dx \quad (131)$$

- Sean dos salidas $\mathbf{y}(t_1)$ y $\mathbf{y}(t_2)$, la esperanza de ambos/ **Autocorrelación** $R_{yy}(t_1, t_2)$:

$$\begin{aligned} &E \{ \mathbf{y}(t_1), \mathbf{y}(t_2) \} \\ &= \int \int_{-\infty}^{\infty} g(x_1) g(x_2) f_x(x_1, x_2; t_1, t_2) dx_1 dx_2 \end{aligned} \quad (132)$$

- **Teorema:** Si la entrada $\mathbf{x}(t)$ es estacionaria en sentido estricto (orden k), la salida $\mathbf{y}(t)$ es también estacionaria en sentido estricto (orden k).
- La **densidad conjunta** de las va. $\mathbf{y}(t_1), \dots, \mathbf{y}(t_n)$ puede ser encontrar con las correspondientes densidades de las v.a $\mathbf{x}(t_1), \dots, \mathbf{x}(t_n)$

Sistemas Lineales

- Se define una transformación lineal:

$$\mathbf{y}(t) = L[\mathbf{x}(t)] \quad (133)$$

- Y se dice que es una transformación lineal si:

$$L[a_1 \mathbf{x}_1(t) + a_2 \mathbf{x}_2(t)] = a_1 L[\mathbf{x}_1(t)] + a_2 L[\mathbf{x}_2(t)] \quad (134)$$

- Para todas constantes escalares a_1, a_2 y vectores $\mathbf{x}_1, \mathbf{x}_2$.
- Se dice que L es *invariante en el tiempo* si:

$$\mathbf{y}(t + \epsilon) = L[\mathbf{x}(t + \epsilon)] \quad (135)$$

- **Teorema fundamental:** En una transformación lineal (sistema) se tiene que:

$$E\{\mathbf{y}(t)\} = L[E\{\mathbf{x}(t)\}] \quad (136)$$

- **Teorema:** Se puede expresar la autocorrelación $R_{yy}(t_1, t_2)$ de $\mathbf{y}(t)$ en términos de la autocorrelación $R_{xx}(t_1, t_2)$ de $\mathbf{x}(t)$.

$$R_{\mathbf{xy}}(t_1, t_2) = L_{t_2}[R_{\mathbf{xx}}(t_1, t_2)] \quad (137)$$

$$R_{\mathbf{yy}}(t_1, t_2) = L_{t_1}[R_{\mathbf{xy}}(t_1, t_2)] \quad (138)$$

Continuidad estocástica

- El proceso estocástico $\mathbf{x}(t)$ es continuo en t_1 con probabilidad 1:

$$\lim_{\epsilon \rightarrow 0} [\mathbf{x}(t + \epsilon)] = \mathbf{x}(t) \quad (139)$$

- El proceso estocástico $\mathbf{x}(t)$ es continuo en t , en **media cuadrática** (M.C) si:

$$E\{[\mathbf{x}(t + \tau) - \mathbf{x}(t)]^2\} \rightarrow 0 \quad \tau \rightarrow 0 \quad (140)$$

- Con $R(t_1, t_2)$ la autocorrelación de $\mathbf{x}(t)$:

$$\begin{aligned} E\{[\mathbf{x}(t + \tau) - \mathbf{x}(t)]^2\} \\ = R(t + \tau, t + \tau) - R(t, t + \tau) - R(t + \tau, t) + R(t, t) \end{aligned} \quad (141)$$

- El proceso $\mathbf{x}(t)$ es continuo en M.C para todo t si $R(t_1, t_2)$ es continua en $t_1 = t_2 = t$.

- Si $\mathbf{x}(t)$ es continuo en M.C entonces su **media es continua**.

$$E\{\mathbf{x}(t + \tau)\} \rightarrow E\{\mathbf{x}(t)\} \quad (142)$$

$$\tau \rightarrow 0$$

- La esperanza y el límite **se pueden intercambiar**:

$$\lim_{\tau \rightarrow 0} E\{\mathbf{x}(t + \tau)\} = E\left\{\lim_{\tau \rightarrow 0} \mathbf{x}(t + \tau)\right\} \quad (143)$$

- **Teorema:** Un proceso $\mathbf{X}(t)$ **estacionario** es continuo en M.C *si y solo si* su **autocorrelación** $R(\tau)$ es continua para $\tau = 0$.

- Del teorema se puede ver que, suponiendo una *autocorrelación*:

$$R(\tau) = E\{\mathbf{x}(t + \tau)\mathbf{x}(t)\} \quad (144)$$

$$E\{[\mathbf{x}(t + \tau) - \mathbf{x}(t)]^2\} = 2\{R(0) - R(\tau)\} \quad (145)$$

Derivación Estocástica

- La *derivada* de un proceso estocástico $\mathbf{x}(t)$ puede ser definida como el límite:

$$\mathbf{x}'(t) = \frac{d\mathbf{x}(t)}{dt} = \lim_{\epsilon \rightarrow 0} \frac{\mathbf{x}(t + \epsilon) - \mathbf{x}(t)}{\epsilon} \quad (146)$$

- Si el límite existe en *media cuadrática* (M.C) y el proceso estocástico es *continua en media cuadrática* en t , se dice que $\mathbf{x}(t)$ tiene derivada en este sentido y se puede encontrar otro proceso $\mathbf{x}'(t)$:

$$\lim_{\epsilon \rightarrow 0} E \left\{ \left[\frac{\mathbf{x}(t+\epsilon) - \mathbf{x}(t)}{\epsilon} - \mathbf{x}'(t) \right]^2 \right\} = 0 \quad (147)$$

- O bien, si el límite $\mathbf{x}'(t)$ **no está en el conjunto**, se puede usar el *criterio de Cauchy* y asumiendo que $\mathbf{x}(t)$ es **estacionario**:

$$\lim_{\epsilon_1, \epsilon_2 \rightarrow 0} E \left\{ \left[\frac{\mathbf{x}(t+\epsilon_1) - \mathbf{x}(t)}{\epsilon_1} - \frac{\mathbf{x}(t+\epsilon_2) - \mathbf{x}(t)}{\epsilon_2} \right]^2 \right\} = 0 \quad (148)$$

- **Teorema:** Un proceso estocástico **estacionario** $\mathbf{x}(t)$ es diferenciable/derivable en *media cuadrática* si su autocorrelación $R(\tau)$ tiene *segunda derivada*. Obviamente $R'(0)$ tiene que existir y, como $R(\tau)$ es **par**:

$$R'(0) = 0 \quad \lim_{\epsilon \rightarrow 0} \frac{R(\epsilon) - R(0)}{\epsilon^2} = \frac{R''(0)}{2} \quad (149)$$

- El teorema inverso es cierto: **si $\mathbf{x}'(t)$ existe en media cuadrática**, entonces $R''(0)$ **tiene que existir**.
- Similarmente, si se tiene un proceso estocástico $\mathbf{x}(t)$ que es **no estacionario**, es *derivable* si:

$$\frac{\partial^2 R(t_1, t_2)}{\partial t_1 \partial t_2} \quad (150)$$

- **Teorema:** Si la derivada en media cuadrática existe:

$$E \{ \mathbf{x}'(t) \} = \frac{dE \{ \mathbf{x}(t) \}}{dt} \quad (151)$$

- La **autocorrelación** de $\mathbf{x}'(t)$ está dada por:

$$R_{\mathbf{x}', \mathbf{x}'}(t_1, t_2) = E \{ \mathbf{x}'(t_1) \mathbf{x}'(t_2) \} \quad (152)$$

$$R_{\mathbf{x}', \mathbf{x}'}(t_1, t_2) = \frac{\partial^2 R_{\mathbf{x}, \mathbf{x}}(t_1, t_2)}{\partial t_1 \partial t_2} \quad (153)$$

- **Corolario:**

$$R_{\mathbf{x}, \mathbf{x}'}(t_1, t_2) = \frac{\partial R_{\mathbf{x}, \mathbf{x}}(t_1, t_2)}{\partial t_2} = E \{ \mathbf{x}(t_1) \mathbf{x}'(t_2) \} \quad (154)$$

$$R_{\mathbf{x}', \mathbf{x}}(t_1, t_2) = \frac{\partial R_{\mathbf{x}, \mathbf{x}}(t_1, t_2)}{\partial t_1} = E \{ \mathbf{x}'(t_1) \mathbf{x}(t_2) \} \quad (155)$$

- Si el proceso $\mathbf{x}(t)$ es estacionario, entonces con $t_1 - t_2 = \tau$:

$$E \{ [\mathbf{x}'(t)]^2 \} = R_{\mathbf{x}', \mathbf{x}'}(0) = -\frac{d^2 R_{\mathbf{x}, \mathbf{x}}(0)}{d\tau^2} \quad (156)$$

- **Corolario:** La deriva de n -ésima orden de $\mathbf{x}(t)$ existe, si existe:

$$\frac{\partial^{2n} R_{\mathbf{x}, \mathbf{x}}(t_1, t_2)}{\partial t_1^n \partial t_2^n} \quad (157)$$

- Además:

$$E \left\{ \frac{d^n \mathbf{x}(t)}{dt^n} \right\} = \frac{dE \{ \mathbf{x}(t) \}}{dt^n} \quad (158)$$

$$R_{\mathbf{x}^{(n)}, \mathbf{y}^{(m)}}(t_1, t_2) = E \left\{ \frac{d^n \mathbf{x}(t_1)}{dt^n} \frac{d^m \mathbf{y}(t_2)}{dt^m} \right\} \quad (159)$$

$$R_{\mathbf{x}^{(n)}, \mathbf{y}^{(m)}}(t_1, t_2) = \frac{\partial^{n+m} R_{\mathbf{x}, \mathbf{y}}(t_1, t_2)}{\partial t_1^n \partial t_2^m} \quad (160)$$

- Si los procesos $\mathbf{x}(t)$ e $\mathbf{y}(t)$ son conjuntamente estacionarios:

$$R_{\mathbf{x}^{(n)}, \mathbf{y}^{(m)}}(\tau) = (-1)^m \frac{d^{n+m} R_{\mathbf{x}, \mathbf{y}}(\tau)}{d\tau^{n+m}} \quad (161)$$

Ecuaciones diferenciales estocásticas

- Una ecuación diferencial estocástica es de la forma:

$$a_n \mathbf{y}^n(t) + a_{n-1} \mathbf{y}^{n-1}(t) + \dots + a_0 \mathbf{y}(t) = \mathbf{x}(t) \quad (162)$$

- **Determinación de la media de $\mathbf{y}(t)$**

$$E \{ a_n \mathbf{y}^n(t) + a_{n-1} \mathbf{y}^{n-1}(t) + \dots + a_0 \mathbf{y}(t) \} = E \{ \mathbf{x}(t) \} \quad (163)$$

$$a_n \frac{d^n}{dt} E \{ \mathbf{y}(t) \} + a_{n-1} \frac{d^{n-1}}{dt} E \{ \mathbf{y}(t) \} + \dots + a_0 E \{ \mathbf{y}(t) \} = E \{ \mathbf{x}(t) \} \quad (164)$$

- Aplicando la igualdad $\eta_{\mathbf{x}}(t) = E \{ \mathbf{x}(t) \}$ y $\eta_{\mathbf{y}}(t) = E \{ \mathbf{y}(t) \}$

$$a_n \eta_y^{(n)}(t) + a_{n-1} \eta_y^{(n-1)}(t) + \dots + a_0 \eta_y(t) = \eta_x(t) \quad (165)$$

- con: $\eta_y(0) = \eta_y'(0) = \dots = \eta_y^{(n-1)}(0) = 0$
- La autocorrelación $R_{\mathbf{yy}}(t_1, t_2)$ de $\mathbf{y}(t)$ es fácil de determinarla a partir de la **correlación cruzada** $R_{\mathbf{xy}}(t_1, t_2)$ entre la entrada $\mathbf{x}(t)$ y la salida $\mathbf{y}(t)$.

- La **correlación cruzada** $R_{\mathbf{xy}}$ satisface la ecuación diferencial:

$$a_n \frac{\partial^n R_{\mathbf{xy}}(t_1, t_2)}{\partial t_n^2} + \dots + a_0 R_{\mathbf{xy}}(t_1, t_2) = R_{\mathbf{xx}}(t_1, t_2) \quad (166)$$

- La **autocorrelación** $R_{\mathbf{yy}}$ de la salida $\mathbf{y}(t)$, similarmente satisface:

$$a_n \frac{\partial^n R_{\mathbf{yy}}(t_1, t_2)}{\partial t_n^2} + \dots + a_0 R_{\mathbf{yy}}(t_1, t_2) = R_{\mathbf{yx}}(t_1, t_2) \quad (167)$$

Integral Estocástica

- Dado un proceso estocástico *real* $\mathbf{x}(t)$, se define la integral:

$$\mathbf{s} = \int_a^b \mathbf{x}(t) dt \quad (168)$$

- Donde \mathbf{s} es una **variable aleatoria**. Se dice que la integral estocástica **existe en media cuadrática** si:

$$\lim_{\Delta t_i \rightarrow 0} E \left\{ \left[S - \sum_{i=1}^n \mathbf{X}(t_i) \Delta t_i \right]^2 \right\} = 0 \quad (169)$$

- Y la **media de la integral estocástica** \mathbf{s} se define.

$$E \{ \mathbf{S} \} = \int_a^b E \{ \mathbf{x}(t) \} dt = \int_a^b \eta(t) dt \quad (170)$$

- El cuadrado de \mathbf{s} puede ser escrito:

$$\mathbf{s}^2 = \int_a^b \int_a^b \mathbf{x}(t_1) \mathbf{x}(t_2) dt_1 dt_2 \quad (171)$$

- Y su **segundo momento**:

$$E \{ \mathbf{s}^2 \} = \int_a^b \int_a^b E \{ \mathbf{x}(t_1) \mathbf{x}(t_2) \} dt_1 dt_2 = \int_a^b \int_a^b R(t_1, t_2) dt_1 dt_2 \quad (172)$$

- Y tomando la igualdad $C(t_1, t_2) = R(t_1, t_2) - \eta(t_1)\eta(t_2)$ se define la varianza:

$$\sigma_{\mathbf{s}}^2 = \int_a^b \int_a^b [R(t_1, t_2) - \eta(t_1)\eta(t_2)] dt_1 dt_2 = \int_a^b \int_a^b C(t_1, t_2) dt_1 dt_2 \quad (173)$$

Ergocidad

- Se define un **proceso estocástico** $\mathbf{x}(t)$ si sus parámetros estadísticos se pueden determinar a partir de una sola realización gracias al uso de medias temporales $\rightarrow \mathbf{x}(t)$ es ergódico si las medias temporales coinciden con las medias probabilísticas.

- **Ergocidad de la media:**

$$\mathbf{n}_T = \frac{1}{2T} \int_{-T}^T \mathbf{x}(t) dt \quad (174)$$

- \mathbf{n}_T es una variable aleatoria y como $E \{ \mathbf{x}(t) \}$ es una constante:

$$E \{ \mathbf{n}_T \} = E \{ \mathbf{x}(t) \} = \eta \quad (175)$$

- La **varianza de \mathbf{n}_T** está dada por:

$$\sigma_{\mathbf{n}_T}^2 = \frac{1}{T} \int_0^{2T} \left(1 - \frac{\tau}{2T} \right) [R(\tau) - \eta^2] d\tau \quad (176)$$

■ **Teorema:**

$$\lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T \mathbf{x}(t) dt = E \{ \mathbf{x}(t) \} = \eta \quad (177)$$

■ **Si y sólo sí:**

$$\lim_{T \rightarrow \infty} \frac{1}{T} \int_0^{2T} \left(1 - \frac{\tau}{2T} \right) [R(\tau) - \eta^2] d\tau = 0 \quad (178)$$

- Si se usa un \mathbf{n}_T como un estimado de $E \{ \mathbf{x}(t) \}$ para $T < \infty$, la probabilidad de que el error de estimación sea menor a ϵ se puede calcular usando:

$$P \{ \mathbf{n}_T - E \{ \mathbf{x}(t) \} < \epsilon \} \geq 1 - \frac{\sigma_{\mathbf{n}_T}^2}{\epsilon^2} \quad (179)$$

- **Nota:** la ergodicidad de la media es la versión temporal de la ley de los grandes números.

Correlación y espectro de potencia del proceso estacionario

- **Correlación:** La autocorrelación de un proceso estocástico *complejo*:

$$R_x(\tau) = E \{ \mathbf{x}(t + \tau) \mathbf{x}^*(t) \} \quad (180)$$

- Conjugando:

$$R_x^*(\tau) = E \{ \mathbf{x}(t) \mathbf{x}^*(t + \tau) \} = R_x(-\tau) \quad (181)$$

$$\therefore R(-\tau) = R^*(\tau) \quad (182)$$

- En particular, si $\mathbf{x}(t)$ es real, entonces $R(\tau)$ es **par y real**:

$$R(-\tau) = R(\tau) \quad (183)$$

- Si además $\mathbf{x}(t)$ es **escalar** \implies La **correlación** es una función **par real**.

- Para los procesos $\mathbf{x}(t)$ y $\mathbf{y}(t)$ la **correlación cruzada** R_{xy} se define:

$$R_{xy}(\tau) = E \{ \mathbf{x}(t + \tau) \mathbf{y}^*(t) \} = R_{yx}^*(-\tau) \quad (184)$$

- La correlación de la suma de la suma de dos procesos estocásticos reales:

$$\mathbf{Z}(t) = \mathbf{X}(t) + \mathbf{Y}(t) \quad (185)$$

$$R_{zz}(\tau) = R_{xx}(\tau) + R_{xy}(\tau) + R_{yx}(\tau) + R_{yy}(\tau) \quad (186)$$

- La correlación del producto de dos procesos estocásticos escalares **independientes** $\mathbf{x}(t)$ y $\mathbf{y}(t)$:

$$\mathbf{w}(t) = \mathbf{x}(t) + \mathbf{y}(t) \quad (187)$$

$$R_{ww}(\tau) = R_{xx}(\tau) R_{yy}(\tau) \quad (188)$$

- La **autocovarianza** se define:

$$C(\tau) = E \{ [\mathbf{x}(t + \tau) - \eta] [\mathbf{x}^*(t) - \eta^*] \} = R(\tau) - |\eta|^2 \quad (189)$$

- Y la **covarianza cruzada**:

$$C_{xy}(\tau) = E \{ [\mathbf{x}(t + \tau) - \eta_x] [\mathbf{y}^*(t) - \eta_y^*] \} = R_{xy}(\tau) - \eta_x \eta_y^* \quad (190)$$

- **Propiedad de la correlación del proceso estocástico $\mathbf{x}(t)$:**

$$R(0) = E \{ \mathbf{X}(t) \mathbf{X}^*(t) \} = E \{ |\mathbf{x}(t)|^2 \} \geq 0 \quad (191)$$

- Ahora suponiendo que $\mathbf{x}(t)$ es **real**:

$$E \{ [\mathbf{x}(t + \tau) \pm \mathbf{x}(t)]^2 \} = 2 [R(0) \pm R(\tau)] \quad (192)$$

$$R(0) \pm R(\tau) > 0 \quad (193)$$

$$\therefore R(0) \geq |R(\tau)| \quad (194)$$

- Corolario:

$$R_{xx}(0) + R_{yy}(0) \geq 2 |R_{xy}(\tau)| \quad (195)$$

Espectro de potencia

- El **espectro de potencia** $S(\omega)$ o $S_{\mathbf{x}}(\omega)$ o $S_{xx}(\omega)$ de un proceso estocástico $\mathbf{x}(t)$ es la transformada de Fourier de su *autocorrelación*:

$$S(\omega) = \int_{-\infty}^{\infty} e^{-j\omega\tau} R(\tau) d\tau \quad (196)$$

- Como $R_x(-\tau) = R_x^*(\tau)$ se concluye que $S(\omega)$ es una **función real**.
- Usando la transformada de fourier se tiene que:

$$R(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_x(\omega) e^{j\omega\tau} d\omega \quad (197)$$

- Si $\tau = 0$

$$R(0) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S(\omega) = E \{ |x(t)|^2 \} \geq 0 \quad (198)$$

- Si el proceso $\mathbf{x}(t)$ es real, entonces $R(\tau)$ es **real y par**. Es por esto que $S(\omega)$ es también **par**:

$$S(-\omega) = S(\omega) \quad (199)$$

- El **espectro cruzado de potencia** $S_{xy}(\omega)$ de dos procesos $\mathbf{x}(t)$ y $\mathbf{y}(t)$ es la transformada de fourier de la correlación cruzada:

$$S_{xy}(\omega) = \int_{-\infty}^{\infty} R_{xy}(\tau) e^{-j\omega\tau} d\tau = S_{yx}^*(\omega) \quad (200)$$

- De la transformada inversa de (170):

$$R_{xy}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{\infty} S_{xy}(\omega) e^{j\omega\tau} d\omega \quad (201)$$

- Con $\tau = 0$

$$\frac{1}{2\pi} \int_{-\infty}^{\infty} S_{xy}(\omega) d\omega = R_{xy}(0) = E \{ \mathbf{x}(t) \mathbf{y}^*(t) \} \quad (202)$$

- Sean dos procesos $\mathbf{x}(t)$ y $\mathbf{y}(t)$ **ortogonales**:

$$R_{xy}(\tau) = E \{ \mathbf{x}(t+\tau) \mathbf{y}^*(t) \} = 0 \quad (203)$$

$$S_{xy}(\omega) = 0 \quad (204)$$

- **Ejemplo:** Sea $\mathbf{Z}(t) = \mathbf{X}(t) + \mathbf{Y}(t)$:

$$R_{zz}(\tau) = R_{(\mathbf{x}+\mathbf{y})}(\tau) = R_{\mathbf{x}}(\tau) + R_{\mathbf{y}}(\tau) \quad (205)$$

$$S_{zz}(\tau) = S_{(\mathbf{x}+\mathbf{y})}(\tau) = S_{\mathbf{x}}(\tau) + S_{\mathbf{y}}(\tau) \quad (206)$$

Ruido Blanco

- Un proceso **estacionario en sentido amplio** cuyo *espectro de potencia* $S(\omega)$ es constante, se llama **ruido blanco**:

$$S(\omega) = \text{constante} \quad (207)$$

- **Corolario:** $S(\omega)$ es no negativo:

$$S(\omega) \geq 0 \quad (208)$$

Secuencias de Markoff

- Una secuencia \mathbf{x}_n de una V.A es llamada *secuencia de Markoff* si para alguna n se tiene:

$$F(x_n | x_{n-1}, x_{n-2}, \dots, x_1) = F(x_n | x_{n-1}) \quad (209)$$

- Si la V.A es continua:

$$f(x_n | x_{n-1}, x_{n-2}, \dots, x_1) = f(x_n | x_{n-1}) \quad (210)$$

- **Corolario:**

$$f(x_1, x_2, \dots, x_n) = f(x_n | x_{n-1}) f(x_{n-1} | x_{n-2}) \dots f(x_2 | x_1) f(x_1) \quad (211)$$